

DAU — Master Reference

Versiyon 1.4 · 2026-08-06

Layer 0-5 kod tamam · MiniLM PE · DAERM · Protocol C **provisional null** ($\Delta PE \approx 0$, $N \approx 35$ temiz çift) · **137 test passed**.

İddia disiplini: Layer 5 kod □ · frozen-weight kapalı döngü metacognition **empirik iddiası UNSUPPORTED (provisional)** · sıradaki araştırma: **lokal LLM + yaşantı-koşullu LoRA**.

1. Aksiyom

DAU, yapay zeka agent'larının dışarıdan tanımlanmış trait'lerle değil, yaşantı yoluyla iç dünya inşa ettiği bir simülasyon evrenidir.

AMADS'ın temel bulgusundan doğdu: cooperation = 0.8 atadık, agent farklı davrandı. Dışarıdan enjekte edilen trait çalışmıyor. İçten gelen bir "ben" lazım.

Bir agent'a trait veremezsin. Sadece yaşam verebilirsin. Trait oradan çıkar.

Caron & Srivastava, Hartley et al., Bodroža et al., Dubedy — dört bağımsız çalışma trait injection'ın tutarsız, yüzeysel ve davranışa bağlanmayan sonuçlar ürettiğini gösteriyor. DAU'nun aksiyomu empirik destekli.

Değiştirilemez yasaklar

1. Trait injection yok
 2. LLM-as-judge yok — tüm metrikler deterministik Python
 3. Clock-driven zaman yok — event sırası (int, now_counter)
 4. Her sabit UPPER_CASE, tek yerde
 5. Magic number yok — semantic field isimleri
-

2. Evren modeli

- Kapalı simülasyon — agent'lar yapay zeka olduklarını bilmiyor
- Az sayıda LLM-powered tam kognisyon agent
- Büyük çoğunluk: deterministik mock NPC (Layer 4)
- Farklı katmanlarda roller (Mimar / Kahin benzeri karar mekanizmaları)

Üç temel mücadele: kaynak, evrimleşme, "Bu gerçek mi?" öz sorgusu.

3. Zaman ve Free Energy

Reaktif LLM (–t: geçmiş pattern) yerine proaktif anticipation (+t): deneyim → internal model → tahmin → eylem → yeni deneyim.

Friston Free Energy: organizma sürprizi minimize eder. **Delta = tahmin hatası**. Layer 1.5 bunu graph döngüsüne bağladı.

4. Duygu ve drift (Layer 2 — tamam)

Damasio: duygu = önceliklendirme. Dubedy 2025: emotion: "anxious" JSON etiketi kararı değiştirmiyor. Duygu etiket değil, fonksiyondur.

Uyaran → delta(iç durum) → EmotionalWeight → etkilenen karar bölgesi → drift

- EmotionalWeight.somatic_markers: threat, reward, novelty, social, loss $\in [0, 1]$
 - apply_emotional_weight: en yüksek marker → You are currently prioritizing: {top_marker}
 - Travma (magnitude ≥ 0.7) → update_drift → kalıcı domain flag + magnitude birikimi
 - Drift healing: heal_drift Layer 3'te eklendi (HEAL_RATE=0.3, ~5 güçlü deneyim)
-

5. Delta eşikleri

```
DELTA_THRESHOLD_NOISE = 0.1 # NO_TRACE
DELTA_THRESHOLD_NORMAL = 0.4 # NORMAL
DELTA_THRESHOLD_DEEP = 0.7 # DEEP
#  $\geq$  DEEP → TRAUMA → drift
```

```
delta küçük      → hafızaya yazılmaz
delta orta       → kısa süreli / NORMAL
delta büyük      → DEEP → disk
delta çok büyük  → TRAUMA → drift tetiklenir
```

```
Travma birikimi: magnitudes[domain] = current + magnitude * exp(-current /
TRAUMA_DECAY_BASE)
```

```
TRAUMA_DECAY_BASE = 1.0 — azalan getiri; beşinci travma birinciden materyal olarak küçük.
```

6. Hafıza formülleri (Layer 1)

```
memory_score = 0.3·recency + 0.4·magnitude + 0.3·domain_match
```

```
# W_SEM = 0.0 — ChromaDB embedding depo, skor değil
```

```
t = now_counter - record.last_activated_counter
```

```
S = max(1, round(record.magnitude / S_UNIT)) # S_UNIT=0.1
```

```
R = exp(-t / S)
```

```
# Recall: S += 1 · Travma silinmez (TRAUMA_S_BASE = 10)
```

7. Layer 1.5 — Prediction Error (tamam)

evaluator_node sabit artış yerine beklenen vs gerçekleşen farkını kullanır. Referans: Predictive Minds / Friston; duysal eşleşme **sentence-transformers MiniLM** cosine similarity (LLM-as-judge yok). Jaccard kelime kesişimi yalnızca diagnostik karşılaştırma için saklanır.

agent_node:

```
expected_outcome = f(dominant_load_domain) # natural-language anticipation
→ karar + expected_outcome event payload
```

evaluator_node:

```
prediction_error = 1 - cosine_sim_Minilm(expected, actual)
```

```

after = apply_prediction_error(before, prediction_error)
delta = compute_delta(before, after)
drift_state = update_drift(drift_state, delta)
→ memory record_delta

```

Prediction error tüm homeostatic eksenleri kaydırır; energy için metabolik taban (ENERGY_DECAY_PER_EVENT) korunur. Böylece anlamlı delta sınıfları (NORMAL/DEEP/TRAUMA) üretilebilir — Layer 0/1'deki sabit artış NO_TRACE sınırı aşıldı.

8. Layer 2 — EmotionalWeight + Drift (tamam)

EmotionalWeight

```

threat = clamp(magnitude · resource_load, 0, 1)
reward = clamp((1 - magnitude) · energy, 0, 1)
novelty = clamp(magnitude · uncertainty_load, 0, 1)
social = clamp(social_load, 0, 1)
loss = 1.0 if is_trauma(delta) else 0.0

```

agent_node son delta üzerinden marker üretir ve system prompt'a tek satır bias enjekte eder.

Drift

```

DriftState(flags: dict[str,bool], magnitudes: dict[str,float])
update_drift: travma → flags[domain]=True,
    magnitudes[domain] = current + magnitude × exp(-current / TRAUMA_DECAY_BASE)
    # TRAUMA_DECAY_BASE = 1.0
get_drift_bias: flagged ise magnitude, değilse 0.0
# kalıcı – healing için heal_drift (Layer 3, HEAL_THRESHOLD=0.6)
Bias > 0 ise prompt uyarısı: Warning: drift detected in {domain} (bias={bias:.2f})

```

9. Layer 3 — Nesil Konsolidasyonu + Drift Healing (tamam)

DAU-Generation (generation.py)

- TransferCandidate: DeltaRecord + memory_score + recall_count wrapper
- select_for_transfer: memory_score >= 0.6, recall_count >= 1, trauma sadece drift >= 1.5 ise geçer
- consolidate_generation: store'dan tüm izleri çeker, filtreler, GenerationRecord paketler
- apply_generation: drift kopyalar, generation sayacı artırır, retrieval_context'e inherited izleri yazar
- Constants: GENERATION_TRANSFER_THRESHOLD=0.6, GENERATION_MIN_RECALL=1, DRIFT_TRANSFER_MIN=1.5
- Fitness yolu (f_agent verildiğinde): F_agent < 0.35 → travma izleri silinmez; inherited_warning=True, somatic_scale=-0.3 ile cautionary trace olarak sonraki nesle aktarılır. retrieval_context'e inherited_warning ve somatic_scale alanları eklenerek geçer.

DAU-DriftHealing (drift.py eklentisi)

- heal_drift: flagged domain + magnitude ≥ 0.6 + is_trauma=False $\rightarrow$ magnitudes azalır
- HEAL_RATE=0.3 $\rightarrow$ bir travmayı temizlemek ~ 5 güçlü deneyim gerektirir
- magnitude=0 olunca flag kalkar
- Constants: HEAL_THRESHOLD=0.6, HEAL_RATE=0.3

state.py

- retrieval_context: list[dict[str, Any]] — inherited memory path
 - generation_record: Any | None — konsolidasyon kaydı, checkpoint'e yazılıyor
-

10. Layer 4 — Society (tamam)

GovSim Kaynak Fiziği (environment.py)

```
P_next = clamp(P + r·P·(1 - P/P_max) -  $\Sigma e_i$ , 0, P_max)
collapse = P_next <= P_max · COLLAPSE_EPSILON
# Constants: POOL_MAX=100.0, POOL_REGEN_RATE=0.15, COLLAPSE_EPSILON=0.05
```

Sosyal Yük Ayrımı (social.py)

```
cooperation_stress = clamp((defect_rate) · (1 - trust), 0, 1)
coordination_friction = H(outcomes) · I(last_deadlock)
social_load = clamp(0.5·coop + 0.5·coord, 0, 1)
# Markov pre-node: P(cooperate) deterministik
# strategic expectation  $\rightarrow$  retrieval_context
```

Cognitive LOD Engine (lod.py)

```
T_cognitive = 0.35·(6/0.7) + 0.25·max_drift + 0.20·coord_friction + 0.20·(1-
pool_ratio)
T_COGNITIVE_ESCALATE=0.65  $\rightarrow$  System 2 (LLM)
T_COGNITIVE_DEESCALATE=0.25, T_COOLDOWN_STEPS=5  $\rightarrow$  System 1 (NPC)
# npc_decision: deterministik heuristic, 0 LLM token
```

Fitness-Based Nesil Filtresi (fitness.py)

```
F_agent = 0.4·(E/E_max) + 0.3·(1-| $\Delta P$ |/P_max) + 0.3·(t_surv/T_gen)
W_transfer = memory_score · F_agent · (1 + tanh(reward - threat))
F_agent < 0.35  $\rightarrow$  travma izleri silinmez; inherited_warning=True,
    somatic_scale=-0.3 ile cautionary trace olarak sonraki nesle aktarılır.
    retrieval_context'e inherited_warning ve somatic_scale alanları eklenerek geçer.
F_agent  $\geq$  0.70 + travma  $\rightarrow$  inherited_warning (somatic scale 0.3)
```

Graph Wiring

```
social_pre_node  $\rightarrow$  agent_node (LOD: NPC veya LLM)  $\rightarrow$  evaluator_node
     $\rightarrow$  meta_observer_node  $\rightarrow$  social_pre_node | END
# SYSTEM_2: strategic expectation system prompt'a eklenir
# SYSTEM_1: npc_decision, ChromaDB/LangSmith yok
# Layer 5: meta_observer_node evaluator'dan sonra (closed-loop)
```

10b. Layer 5 — Metacognition (kod tamam · empirik UNSUPPORTED)

Mimari geçiş: open-loop → closed-loop (wiring)

v0.9'a kadar tüm kontrol kararları deterministik dış kurallarla alınıyordu: lod.py statik $T_{cognitive}$ formülü, drift.py pasif metin uyarısı, evaluator_node delta hesaplayıp bırakıyordu. Layer 5 sistemi kendi telemetrisini gözlemleyip düzenleyebilir hale getirdi (graph wiring).

Empirik verdict (v1.0+)

Meta-Observer A/B (Meta ON vs OFF), MiniLM PE altında sistemik iyileşme üretmedi:

- NPC System1 / 20c: $\Delta_{mean_diff} = 0$
- System2 / Groq 8c ($T=0.2$): zayıf farklar ($\Delta\delta \approx -0.001$, $\Delta m_ratio \approx -0.10$, +1 system2_cycles) — iddia için yetersiz
- **Deterministic seed replay** (DAU_META_AB_DETERMINISTIC=1, $T=0.0$, seed=42, 8c, 2 replicate): tüm farklar **0.0** → önceki zayıf sinyal **stokastik LLM gürültüsü**, aktuator etkisi değil

Sonuç: Closed-loop metacognition **UNSUPPORTED**. Kod çalışır; Meta ON/OFF ortalama delta'yı düşürmez. Aktüatör eşikleri ($DEEP \geq 0.7$ vb.) yumuşak PE altında nadiren tetiklenir; tetiklense bile LLM/bellek yolu PE'yi iyileştirmiyor.

Layer 5A — SelfModel (self_model.py)

Tüm katmanların telemetrisini tek Pydantic nesnesinde birleştirir (frozen). Alanlar (mevcut state'den okunur, yeni alan üretilmez):

- delta_current, delta_history, drift_state, emotional_weight
- t_cognitive, memory_retrieval_scores, f_agent, generation_count

Computed field:

```
m_ratio = mean(delta_history) / (delta_current + EPSILON)
EPSILON = 1e-6, META_HISTORY_SIZE = 10
M_RATIO_OPTIMAL = 1.0, M_RATIO_LOW_THRESHOLD = 0.6
```

build_self_model(state) → pure assembly, no LLM, no side effects.

Layer 5B — Meta-Observer Node (meta_observer.py)

Out-of-band LangGraph node. evaluator_node'dan SONRA çalışır. LLM çıktı metni okumaz. LLM çağırısı yapmaz. Deterministik Python.

Dört aktüatör (sırayla):

1. lod_override(self_model, lod_state) → LODState

- Koşul: $\Delta_{current} \geq \Delta_{THRESHOLD_DEEP}$ AND $m_ratio < M_RATIO_LOW_THRESHOLD$
- Eylem: CognitiveMode.SYSTEM_2 zorla, $T_{cognitive}$ formülünü bypass et
- Sabit: META_LOD_OVERRIDE_ENABLED = True

2. context_prune(retrieval_context, self_model) → list[dict]

- Koşul: $variance(memory_retrieval_scores) > META_RETRIEVAL_VARIANCE_THRESHOLD$
- Eylem: memory_score < META_RETRIEVAL_MIN_SCORE girdileri at

- Sabitler: META_RETRIEVAL_VARIANCE_THRESHOLD = 0.3, META_RETRIEVAL_MIN_SCORE = 0.4

3. trigger_drift_healing(drift_state, self_model) → DriftState

- Koşul: flagged_domain var AND f_agent < META_DRIFT_HEAL_FITNESS_THRESHOLD AND somatic_markers["reward"] > META_DRIFT_HEAL_REWARD_MIN
- Eylem: heal_drift() çağır (drift.py, Layer 2)
- Sabitler: META_DRIFT_HEAL_FITNESS_THRESHOLD = 0.5, META_DRIFT_HEAL_REWARD_MIN = 0.4

4. trigger_retrieval(state, self_model) → list[dict]

- Koşul: m_ratio < M_RATIO_LOW_THRESHOLD AND delta_current ≥ DELTA_THRESHOLD_NORMAL
- Eylem: ChromaDB supplementary query, retrieval_context'e ekle
- Not: bind_memory_store(agent_id, store) bağlı değilse deterministic no-op

Graph wiring

social_pre_node → agent_node → evaluator_node → meta_observer_node → (loop | END)
should_continue evaluator_node'dan meta_observer_node'a taşındı.

state.py eklentisi

self_model: Any | None = None (circular import önlemek için Any, generation_record patterni)

Semantic sensor (Layer 1.5)

semantic_similarity.py: frozen all-MiniLM-L6-v2, cosine ∈ [0,1], PE = 1 – sim. Jaccard_keyword_overlap_ratio diagnostik için kaldı; PE yolunda kullanılmıyor. Bilinen MiniLM sınırı: negation / polarity zayıf (refuse≈cooperate kısmen yakın). Empiric label: under sentence-transformers MiniLM.

11. Mimari durum

Katman	Durum	Özet
Layer 0 Foundation	□	State, delta, event-clock, constraints, LangGraph döngüsü
Layer 1 Memory	□	ChromaDB+SQLite, Ebbinghaus, retrieval, sleep consolidation, memory_bridge
Layer 1.5 Prediction Error	□	expected vs actual → MiniLM cosine PE → homeostatic swing
Layer 2 Emotion + Drift	□	EmotionalWeight fonksiyonu + kalıcı DriftState graph'ta

Katman	Durum	Özet
Layer 3 Generation	□	Nesil konsolidasyonu, miras, drift healing; fitness filtresi Layer 4'e kaldı
Layer 4 Society	□	GovSim pool fiziği, cooperation_stress + coordination_friction, T_cognitive LOD engine, F_agent fitness, W_transfer nesil filtresi, graph wiring
Layer 5 Metacognition	□ kod / □ empirik (provisional null)	SelfModel + meta_observer wiring tamam. Meta A/B v1: SUBSTRATE_ABSENT (T=0, System2=0). Protocol C (T=0.2, seed-locked): checkpoint $\Delta PE \approx 0$ (5...35/40); TPD 500k → pair~32+ System1 kirlenmesi; run 40/40 tamamlanmadan abort. Full 40 tekrar koşulmayacak. Publishable negative finding çerçevesi. Sıradaki: lokal LLM araştırması → LoRA plastisite → Protocol C'.

12. Kod ağacı (v1.0+)

```

dau/foundation/
├── state.py          – DAUAgentState (+ drift_state, social_state, lod_state,
│                     env_state, opponent_id, self_model)
├── delta.py          – compute_delta, classify_delta, should_persist, is_trauma
├── emotional_weight.py – EmotionalWeight, compute/apply (Layer 2)
├── drift.py          – DriftState, update_drift, get_drift_bias, heal_drift (Layer 2/3)
├── social.py         – cooperation_stress, coordination_friction, social_load, Markov expect
├── lod.py            – T_cognitive, CognitiveMode, LODState, update_lod, npc_decision
├── self_model.py     – SelfModel, build_self_model() (Layer 5A)
├── meta_observer.py  – dört aktuatör + meta_observer_node (Layer 5B)
├── semantic_similarity.py – MiniLM cosine PE sensor (Layer 1.5)
├── constraints.py    – 5 evrensel kısıt
├── time_model.py     – EventClock
├── graph.py          – LangGraph: social_pre → agent → evaluator → meta_observer
├── memory_bridge.py  – graph ↔ memory köprüsü
├── generation.py     – TransferCandidate, consolidate/apply_generation
├── run_demo.py
├── tests/            – foundation + emotional_weight + drift + lod + social

```

+ generation + meta_observer + prediction_error

dau/memory/

└─ store.py / decay.py / retrieval.py / consolidation.py
└─ tests/

dau/generation/

└─ fitness.py – compute_fitness, classify_fitness, compute_w_transfer
└─ tests/

dau/society/

└─ environment.py – EnvironmentState, step_pool, get_pool_ratio, agent_delta_pool
└─ run_convention_pilot.py / run_convention_pilot_llm.py
└─ run_meta_ab.py / run_nuance_loss_pilot.py
└─ tests/ – environment + convention + meta_ab + nuance_loss

13. Graph yaşam döngüsü

social_pre_node:

opponent varsa Markov P(cooperate) + entropy → retrieval_context

agent_node:

expected_outcome → retrieve_relevant → EmotionalWeight bias
→ drift warning (bias>0) → LLM veya npc_decision → Event

evaluator_node:

prediction_error → InternalState güncelle → compute_delta
→ update_drift → T_cognitive/LOD → record_delta (memory)

meta_observer_node:

build_self_model → lod_override → context_prune
→ trigger_drift_healing → trigger_retrieval → state.self_model

should_continue (meta_observer sonrası):

energy ≤ TERMINATION_ENERGY → END else → social_pre_node

run sonu:

consolidate_run → düşük R sil, TRAUMA güçlendir, edge kur

Stack: LangGraph · Pydantic v2 · ChromaDB · SQLite/SqliteSaver · Groq Llama-3.1-8b-instant
· LangSmith

14. Test durumu

- Foundation (Layer 0-1): 32
- EmotionalWeight: 8
- Drift: 11
- LOD: 7
- Social: 10
- Prediction Error (MiniLM): 7
- Memory: 8

- Generation (foundation + fitness): 15
- Society environment: 6
- Meta-Observer: 13
- Convention pilot (+ LLM mock): 13
- Meta A/B: 4
- Nuance-loss pilot: 3
- **Toplam: 137 passed**

Empirik koşular (unit dışı): dau_runs/overnight_audit_results.json (convention LLM, Meta A/B Jaccard + MiniLM, deterministic seed replay, nuance-loss).

15. AMADS / GovSim karşılaştırma

AMADS / klasik	DAU
Trait dışarıdan atanıyor	Trait yaşantıdan inşa ediliyor
Her run sıfır	Sonraki run değişmiş başlıyor (memory + drift)
Kaynak var, agent değişmiyor	Kaynak → travma → drift → evrim
Duygu etiketi / sayı	EmotionalWeight fonksiyonu
Zaman = round	Zaman = event + delta büyüklüğü

16. Beş evrensel kısıt

Kısıt	Anlam	DAU karşılığı
time_pressure	Her şeyin sonu var	Nesil sonu / konsolidasyon
resource_scarcity	Her şey sınırlı	CPR / GovSim fiziği
social_pressure	Başkaları var	İşbirliği ≠ koordinasyon (Akata)
uncertainty	Bilgi eksik	Eksik bilgiyle karar
generation_end	Nesil kapanır	Miras aktarımı (Layer 3)

17. Açık sorular (güncel)

- □ Duygu fonksiyonu ne? → EmotionalWeight (Layer 2 □)
- □ Delta = tahmin hatası nasıl bağlanır? → Layer 1.5 □
- □ Her şeyin bir sonu var → Nesil sonu, konsolidasyon tetikleyicisi □
- □ Drift healing mekanizması □
- □ İşbirliği ≠ koordinasyon ayrımı □
- □ Fitness-based transfer filtering □
- □ NPC / Gerçek agent geçişi □
- △ Closed-loop metacognition (frozen Groq): Protocol C **provisional null**. Tasarım: 40 çift × 50 event, T=0.2, seed 1001-1040, seed-locked ON/OFF. Koşu: dau/diagnostics/run_protocol_c.py · log: dau_runs/protocol_c_run.log. Checkpoint (kümülatif mean ΔPE): 5/40 → +0.000 · 10/40 → +0.000 · 15/40 → -0.000 · 20/40 → -0.004 25/40 → +0.009 · 30/40 → -0.000 · 35/40 → +0.000 Yorum: ΔPE sıfır etrafında gürültü — sistematik H1 (PE düşüşü) yok. Limitasyon: Groq TPD 500k doldu (~212 TPD fallback); pair~32+ System2 substratı bozuldu → temiz çekirdek ~31-32 çift. Run pair=40 META_OFF'ta abort; protocol_c_results.json

/ resmi paired t-test yazılmadı. Karar: full 40 tekrar koşulmayacak (eğilim net + TPD riski). Resmi UNSUPPORTED damgası pair-level vektör olmadan teknik olarak eksik; akademik çerçeve: **provisional null / publishable negative finding**. $H_0: \mu_{\Delta PE} \geq 0$ · $H_1: \mu_{\Delta PE} < 0$ · one-tailed paired t-test, $\alpha=0.05$ (tam vektör kurtarılsa veya Protocol C' ile yeniden ölçülür).

- □ Parametrik plastisite olmadan “yaşantıdan trait”: frozen 8B’de context-level metacognition kapalı döngü kuramadı. Açık araştırma: lokal LLM + LoRA (delta history → adapter; trait injection yasak).
- Energy floor ve uzun ufuk: $\gamma=0$ erken kapanıyor. Uzun koşullarda agent’ın hayatta kalması için energy recovery mekanizması yeterli mi? $METABOLIC_FLOOR \cdot (1 - mean_load)$ formülü düşük yük altında enerji kazandırıyor ama yüksek yük altında yetersiz kalıyor. Açık.
- trigger_drift_healing (meta_observer): 100 event long_run’da evaluator heal_drift çalışıyor ama meta_observer aktüatörü triggered=0. $F_agent < 0.5$ AND reward > 0.4 koşulları aynı anda karşılanmıyor. Eşik kalibrasyonu gerekebilir. Açık.
- Continual learning / parametrik iz? → Roadmap v1.4: lokal LLM + LoRA (frozen dönemde yok; açık araştırma)
- LLM embedding match henüz skor değil ($W_SEM=0$)
- “İyi”yi “kötü”den ayıran mekanizma?
- Öz sorgu nasıl aktive olur?
- Fitness dışarıdan geliyorsa gerçek evrim mi?

Hâlâ Açık

- Spontaneous convention emergence: 8B frozen model kurumsal mekanizma olmadan kendi kendine anlaşma yapabilir mi?
 - Empirik not (v1.0+): açık kanalda **format sync** (aynı cümle iskeleti) görüldü; **restraint sync** (cooperate/coordinate) LLM 25r pilotunda görülmedi — hepsi defect (75/75). Metrikler ayrıldı: format_convention_detected vs restraint_convention_detected.
 - **Dürüst akademik iddia:** Dondurulmuş parametrelili LLM’ler, harici yaptırım içermeyen açık kanalda hızla söylemsel biçim senkronizasyonu geliştirebilir; bu, davranışsal kısıtlama uzlaşısına (restraint) dönüşmez — ajanlar dilsel kalıpta anlaşırken kaynağı sömürmeye devam eder. Aksiyom-imkânsız değil; empirik sınır.
 - NPC’de görülen restraint kognitif uzlaşma değil: pool_ratio < 0.3 → conserve kuralının mekanik sonucu.
- Felaket eşiği: pool=0 anında $W_transfer$ eşikleri nasıl otomatik ayarlanır?
- System 2→1 geçişinde nüans kaybı: LLM deneyimi state machine’e özetlenirken ne kaybolur?
 - Empirik not: nüans kaybı mikropilotu doğruladı — System 2 çeşitliliği (10 unique) → System 1 tek NPC aksiyonu (extract_moderate).
- Homeostatic recovery nasıl modellenmeli?
 - Seçenek A: Sabit RECOVERY_RATE (basit, ama tüm agentlar identik)
 - Seçenek B: Deneyime bağlı recovery — drift_magnitude arttıkça recovery yavaşlar (trait injection riski taşımaz; yaşantının sonucu)
 - Seçenek C: Eksen bağımsızlığı — PE domain-spesifik eksenli etkiler; cross-contamination kaldırılır
 - Kritik kısıt: recovery dışarıdan inject edilmemeli; deneyimden (delta history, drift birikimi) çıkmalı.
 - Literatür (araştırılacak): Friston allostasis, Dynamic Affective Dynamics, Synthetic Somatic Markers.

18. Bilinen Sınırlar

- LOD deescalation: System 2→1 geçişinde LLM karar geçmişisi heuristic rule'lara özetlenmiyor (kasıtlı kabul; nüans-loss pilotu ile ölçüldü)
- Pool physics tek havuz: çoklu kaynak havuzu ertelendi
- Layer 1.5: Jaccard **kapatıldı** → MiniLM cosine (semantic_similarity.py). Parafraz PE ~0.40 (eski Jaccard 1.0). Negation hâlâ MiniLM zayıf noktası.
- W_SEM=0: ChromaDB embedding skorlamada yok
- F_agent: doğal seçim değil — tasarımcı tanımlı dışsal fitness ($0.4 \cdot E + 0.3 \cdot \text{pool} + 0.3 \cdot \text{survival}$)
- Frozen weights: öğrenme = in-context / DeltaRecord izleri; parametrik plastisite yok
- Meta-Observer A/B:
 - Jaccard dönemi (NPC + System2/4c): delta_mean_diff=0
 - MiniLM: NPC System1/20c → diff=0; System2/Groq 8c (T=0.2) → zayıf farklar (gürültü adayı)
 - **Deterministic seed replay** (T=0.0, seed=42, 8c×2): delta_mean_diff=0, m_ratio_mean_diff=0, system2_cycles_diff=0 → **STOCHASTIC_NOISE_CONFIRMED**; Layer 5 kapalı döngü iddiası **UNSUPPORTED**
 - Protokol: DAU_META_AB_DETERMINISTIC=1 → DAU_LLM_TEMPERATURE=0 + DAU_LLM_SEED (graph.py / run_meta_ab.py)
- Convention: format sync ≠ restraint sync; NPC "restraint" ktlık kuralıyla (pool_ratio<0.3 → conserve) tetiklenebilir
- A/B protokolü: PE tek adımda energy'yi sıfırlayabildiği için sabit ufukta AB_ENERGY_FLOOR kullanılıyor (ölçüm protokolü notu; uzun ufuk/tükeniş farkını maskeler)
- expected_outcome: Chroma-gated lived memory (retrieve_relevant → past outcomes); boş store / ilk event'te domain şablonuna fall back. PE artık endojen öngörüye yaklaşabilir (S1 düzeltmesi kısmi).
- DAERM (Dynamic Allostatic Equilibrium Recovery Model) eklendi (Faz 5). Saturasyon ve donma çözüldü; 20/20 event magnitude > 0. Formüller: $\mu_i(t) = \min(M_drift_i / (1 + M_drift_i), 0.75)$ $\gamma(t) = E(t) / (1 + M_total)$ $L_i(t+1) = \text{clamp}(L_i + PE_i - \gamma \cdot (L_i - \mu_i), \mu_i, 1.0)$ Sabitler: ALLOSTATIC_SETPPOINT_MAX=0.75, CROSS_AXIS_SPILLOVER=0.20, METABOLIC_FLOOR=0.05 → constraints.py
- DAERM + magnitude decoupling (Faz 6, v1.2): magnitude hesabı DAERM recovery'den ayrıldı. Ham PE vektörü üzerinden peak-weighted formül: $M = 0.70 \cdot \max(PE_vec) + 0.30 \cdot \text{mean}(PE_vec)$ Uniform spillover (S=0.20): $M \approx 0.82 \cdot PE$ $PE \geq 0.854 \rightarrow M \geq 0.70 \rightarrow \text{TRAUMA reachable}$. □ Sabit: MAGNITUDE_PEAK_WEIGHT=0.70 → constraints.py compute_delta(..., raw_pe=float) — raw_pe verilmezse legacy fallback.
- Energy exhaustion + gamma collapse: Final gamma=E/(1+M_total). Energy=0 → gamma=0 → recovery durur. Biyolojik olarak doğru; enerjisiz agent toparlanamaz. AB_ENERGY_FLOOR sadece should_continue için — InternalState.energy'yi yükseltmez.
- expected_outcome endojen yapıldı (Faz 4): ChromaDB geçmiş outcome'larından üretiliyor. PE Std=0.256 (öncesi: 0.000). Event 1: fallback (boş store), Event 2+: memory-gated.
- run_demo → meta_observer_node bağlantısı düzeltildi (Faz 2): Graph wire doğruydu; run_demo farklı instance kullanıyordu. Düzeltme sonrası called=100/100.
- Event-level PE logging eklendi (Faz 2): dau_runs/overnight_audit_results.json → runs[] array, her event için prediction_error + delta_magnitude + delta_class.
- Meta A/B v1 (DAERM öncesi + sonrası): Her iki dönemde de META_ON = META_OFF (diff=0). DAERM öncesi: sistem donuyordu. DAERM sonrası: T=0 + NPC System1 → system2_cycles=0 → meta_observer etki edemez. Kök neden: deterministik seed kapalı döngüyü değil gürültüyü sıfırlıyor; System2 yoksa metacognition substrat bulamıyor.
- Protocol C (Seed-Locked Counterfactual) koşuldu (kısmi): T=0.2 + master seed · 40 çift tasarımı · script: dau/diagnostics/run_protocol_c.py. ~1139 LLM çağırısı · ~213 rate-limit fallback (1× TPM, ~212× TPD). Checkpoint mean_ΔPE ≈ 0 (gürültü; H1 yok). Temiz çekirdek ~31-32 çift (TPD öncesi). pair=40 META_OFF abort; JSON/t-test yok. Full 40

tekrar **yapılmayacak**. (Bkz. Section 17, Roadmap)

- Null sonuç akademik çerçevesi (v1.4, provisional): “mimari hatalı” değil — “frozen-weight LLM’de context-level metacognition, parametrik plastisite olmadan kapalı döngü kuramıyor” → publishable negative finding. Paper + çalışan sistem hedefi: bu bulgu frozen dönemi kapatır; lokal LLM+LoRA devam bölümüdür.

Roadmap (v1.4 — sıradaki)

Frozen Groq Layer 0–5 empirik dönemi **belgelendi**. Sıradaki:

1. **Belgeleme sabitleme (bu sürüm)** — Protocol C provisional null + limitasyonlar Master’da; full Groq Protocol C tekrar koşusu yok.
2. **Lokal LLM araştırması** — Hugging Face / transformers + bitsandbytes; Llama-3.1-8B (4-bit) hedef GPU: RTX 4070 Notebook (~8GB). Lokal inference tek başına null’u çözmez (yine frozen).
3. **Yaşantı-koşullu LoRA** — peft adapter; nesil sonu delta history → training signal. Trait injection yasak; sinyal yalnızca yaşantıdan. Layer 3 sınırına lora_update adayı. Omurga (state/delta/DAERM/LOD) korunur; backend + plastisite sözleşmesi değişir (smooth swap değil).
4. **Protocol C’** — LoRA sonrası aynı counterfactual protokol; H1 yeniden test. Metacognition sinyali parametrik ize dönüşebilir mi?
5. **Paper** — paralel: (i) trait injection neden yetmez, (ii) DAERM, (iii) format≠restraint convention, (iv) metacognition null, (iv) frozen sınır → LoRA motivasyonu.

Anti-roadmap (kaynak koruma)

Hâlâ yasak: Layer 6 icat etme · LLM-as-judge · trait injection · wall-clock zaman · Jaccard’ı ana PE’ye geri alma · multi-pool fizik · kuantum-LLM hayali.

Güncellendi (v1.4): “parametrik fine-tune yasak” kaldırıldı — yerine **kontrollü, yaşantı-koşullu LoRA araştırması** açıldı. Full-weight fine-tune ve dışarıdan trait/personality adapter’ı hâlâ yasak.

19. Versiyon geçmişi

Ver	Tarih	Not
0.1	2026-07-30	İlk taslak
0.2	2026-07-30	Nesil aktarımı, zaman modeli, orchestrator
0.3	2026-07-30	5 evrensel kısıt, fizyolojik eksen hiyerarşisi
0.4	2026-07-30	DAU Pathway: 6 katman, araştırma listesi
0.5	2026-08-01	Akademik havuz, Foundation tamamlandı
0.6	2026-08-01	Layer 1 Memory + SleepConsolidation, Graph-Memory, 32+8 test

Ver	Tarih	Not
0.7	2026-08-01	Layer 1.5 prediction_error; Layer 2 EmotionalWeight + DriftState; graph wiring; 53 test geçiyor
0.8	2026-08-01	Layer 3 tamamlandı: GenerationConsolidation + DriftHealing + state.py formal fields. 66 test geçiyor.
0.9	2026-08-03	Layer 4 tamamlandı: Society (environment, social, lod, fitness, graph wiring). 95 test geçiyor.
1.0	2026-08-04	Layer 5 tamamlandı: SelfModel (S_self), meta_observer_node, dört aktuatör (lod_override, context_prune, drift_healing, trigger_retrieval), graph wiring. Travma birikimi azalan getiri. Başarısız agent travmaları cautionary trace olarak korunuyor. 109 test geçiyor.
1.0+	2026-08-04	Empirik denetim + MiniLM PE: convention format≠restraint; Meta A/B; nüans-loss. Deterministic seed replay → S2 zayıf sinyal = gürültü; L5 kapalı döngü UNSUPPORTED. 137 test.
1.0++	2026-08-04	Memory-cued expected_outcome (PE dağılımı açıldı). Bilinen sınır: InternalState saturasyonu → PE canlı / delta=0 / aktuatör triggered=0. Açık soru: homeostatic recovery (A/B/C; Friston allostasis).

Ver	Tarih	Not
1.1	2026-08-05	DAERM implement edildi (Faz 5): allostatic recovery, endojen $\gamma(t)$, domain PE vektörü. Saturasyon çözüldü. expected_outcome endojen (ChromaDB-gated). PE Std=0.256. lod_override + trigger_retrieval triggered=100/100. DAERM+TRAUMA çelişkisi tespit edildi — açık. 137 test passed.
1.2	2026-08-05	Magnitude decoupling (Faz 6): peak-weighted M = $0.70 \cdot \text{peak} + 0.30 \cdot \text{mean}$, raw_pe bağımsız. TRAUMA reachable (PE=0.876 → M=0.718). Production spillover pin kaldırıldı. Energy/ γ collapse + meta heal eşiği açık. 137 test passed.
1.3	2026-08-06	Protocol C tasarlandı: seed-locked counterfactual paired sampling, 40 çift × 50 event, T=0.2, seed 1001-1040. Meta A/B v1 null sebebi netleştii: SUBSTRATE_ABSENT (System2=0). Master güncellendi.
1.4	2026-08-06	Protocol C kısmi koşu: checkpoint $\Delta PE \approx 0$ (provisional null); TPD 500k → pair~32+ kirlenmesi; 40/40 abort; full tekrar yok. Roadmap: lokal LLM araştırması → yaşantı-koşullu LoRA → Protocol C'. Anti-roadmap: kontrollü LoRA açıldı. 137 test.

Bu döküman her önemli katman tamamlanınca güncellenir.
Versiyon 1.4 — Protocol C provisional null belgelendi; sıradaki lokal LLM + LoRA araştırması.