

DAU — Master Reference

Versiyon 1.6 · 2026-08-06

Layer 0–5 kod tamam · MiniLM PE · DAERM · Protocol C **paper-locked negative finding** (Δ PE 0, N 35 temiz çift; pair t-test yok — stats caveat) · Protocol C mini **WEAK_LORA appendix** · C v2 smoke **SMOKE_SEPARATION** (N=1; significance yok) · **162+** test.

İddia disiplini: Layer 5 kod · frozen-weight kapalı döngü metacognition **UNSUPPORTED (paper-locked null)** · yaşantı-LoRA mini **WEAK_LORA_HYPOTHESIS** (appendix; default path değil) · C v2 1-seed smoke: lived < null/shuffle (**SMOKE_SEPARATION**); N=15 otomatik değil — tartışma adayı. DAU_LORA_ENABLED=0.

Faz 0 kilit: Frozen Protocol C null **paper-locked**; full Groq Protocol C tekrar yok.

Lokal / LoRA spike (v1.5–1.6): - Flags: DAU_LLM_BACKEND=groq|local (default groq), DAU_LORA_ENABLED=0 (default; **açık bırakılmadı**). - VRAM spike **GO**: Llama-3.1-8B 4-bit + MiniLM(CPU) + QLoRA micro-train (r=16, seq=128); peak **6.4 GiB** on RTX 4070 Laptop 8GB. - Protocol C mini **live** (local, Groq yok): N=3 (seeds 2001–2003), 50 event/arm, T=0.2, shared adapter, train-then-A/B, null+shuffle. mean Δ PE_lived **0.001** · null **−0.008** · shuffle **0.010** · wall **97 dk** → **WEAK_LORA_HYPOTHESIS** (sinyal v1 / placeholder train). - Protocol C **v2 smoke** (local): N=1 seed 2001, DAU_CPRIME_SIGNAL=v2, PE-ranked pref + lived-train kablosu; Δ PE_lived **−0.026** · null **+0.006** · shuffle **+0.016** · wall **33 dk** → **SMOKE_SEPARATION** (significance claim yok; N expand tartışılır). - Omurga (state/delta/PE/drift/LOD/meta_observer) değişmedi. - Araştırma raporu: docs/DAU_RESEARCH_REPORT_plasticity_2026-08.md.

1. Aksiyom

DAU, yapay zeka agent'larının dışarıdan tanımlanmış trait'lerle değil, yaşantı yoluyla iç dünya inşa ettiği bir simülasyon evrenidir.

AMADS'ın temel bulgusundan doğdu: **cooperation** = 0.8 atadık, agent farklı davrandı. Dışarıdan enjekte edilen trait çalışmıyor. İçten gelen bir “ben” lazım.

Bir agent'a trait veremezsin. Sadece yaşam verebilirsin. Trait oradan çıkar.

Caron & Srivastava, Hartley et al., Bodroža et al., Dubedy — dört bağımsız çalışma trait injection'ın tutarsız, yüzeysel ve davranışa bağlanmayan sonuçlar ürettiğini gösteriyor. DAU'nun aksiyomu empirik destekli.

Değiştirilemez yasaklar

1. Trait injection yok
2. LLM-as-judge yok — tüm metrikler deterministik Python
3. Clock-driven zaman yok — event sırası (**int**, **now_counter**)
4. Her sabit **UPPER_CASE**, tek yerde
5. Magic number yok — semantic field isimleri

2. Evren modeli

- Kapalı simülasyon — agent'lar yapay zeka olduklarını bilmiyor
- Az sayıda LLM-powered tam kognisyon agent
- Büyük çoğunluk: deterministik mock NPC (Layer 4)
- Farklı katmanlarda roller (Mimar / Kahin benzeri karar mekanizmaları)

Üç temel mücadele: kaynak, evrimleşme, “Bu gerçek mi?” öz sorgusu.

3. Zaman ve Free Energy

Reaktif LLM (−t: geçmiş pattern) yerine proaktif anticipation (+t): deneyim → internal model → tahmin → eylem → yeni deneyim.

Friston Free Energy: organizma sürprizi minimize eder. **Delta = tahmin hatası**. Layer 1.5 bunu graph döngüsüne bağladı.

4. Duygu ve drift (Layer 2 — tamam)

Damasio: duygu = önceliklendirme. Dubedy 2025: emotion: "anxious" JSON etiketi kararı değiştirmiyor. Duygu etiket değil, fonksiyondur.

Uyaran → delta(iç durum) → EmotionalWeight → etkilenen karar bölgesi → drift

- EmotionalWeight.somatic_markers: threat, reward, novelty, social, loss [0, 1]
 - apply_emotional_weight: en yüksek marker → You are currently prioritizing: {top_marker}
 - Travma (magnitude 0.7) → update_drift → kalıcı domain flag + magnitude birikimi
 - Drift healing: heal_drift Layer 3'te eklendi (HEAL_RATE=0.3, ~5 güçlü deneyim)
-

5. Delta eşikleri

```
DELTA_THRESHOLD_NOISE = 0.1 # NO_TRACE
DELTA_THRESHOLD_NORMAL = 0.4 # NORMAL
DELTA_THRESHOLD_DEEP = 0.7 # DEEP
# DEEP → TRAUMA → drift
```

```
delta küçük → hafızaya yazılmaz
delta orta → kısa süreli / NORMAL
delta büyük → DEEP → disk
delta çok büyük → TRAUMA → drift tetiklenir
```

Travma birikimi: $magnitudes[domain] = current + magnitude \times \exp(-current / TRAUMA_DECAY_BASE)$
TRAUMA_DECAY_BASE = 1.0 — azalan getiri; beşinci travma birinciden materyal olarak küçük.

6. Hafıza formülleri (Layer 1)

```
memory_score = 0.3·recency + 0.4·magnitude + 0.3·domain_match
# W_SEM = 0.0 - ChromaDB embedding depo, skor değil

t = now_counter - record.last_activated_counter
S = max(1, round(record.magnitude / S_UNIT)) # S_UNIT=0.1
R = exp(-t / S)
# Recall: S += 1 · Travma silinmez (TRAUMA_S_BASE = 10)
```

7. Layer 1.5 — Prediction Error (tamam)

evaluator_node sabit artış yerine beklenen vs gerçekleşen farkını kullanır. Referans: Predictive Minds / Friston; duyuşal eşleşme **sentence-transformers MiniLM** cosine similarity (LLM-as-judge yok). Jaccard kelime kesişimi yalnızca diagnostik karşılaştırma için saklanır.

```

agent_node:
    expected_outcome = f(dominant_load_domain) # natural-language anticipation
    → karar + expected_outcome event payload

evaluator_node:
    prediction_error = 1 - cosine_sim_MinilM(expected, actual)
    after = apply_prediction_error(before, prediction_error)
    delta = compute_delta(before, after)
    drift_state = update_drift(drift_state, delta)
    → memory record_delta

```

Prediction error tüm homeostatic eksenleri kaydırır; energy için metabolik taban (ENERGY_DECAY_PER_EVENT) korunur. Böylece anlamlı delta sınıfları (NORMAL/DEEP/TRAUMA) üretilebilir — Layer 0/1'deki sabit artış NO_TRACE sınırı aşıldı.

8. Layer 2 — EmotionalWeight + Drift (tamam)

EmotionalWeight

```

threat = clamp(magnitude · resource_load, 0, 1)
reward = clamp((1 - magnitude) · energy, 0, 1)
novelty = clamp(magnitude · uncertainty_load, 0, 1)
social = clamp(social_load, 0, 1)
loss = 1.0 if is_trauma(delta) else 0.0

```

agent_node son delta üzerinden marker üretir ve system prompt'a tek satır bias enjekte eder.

Drift

```

DriftState(flags: dict[str,bool], magnitudes: dict[str,float])
update_drift: travma → flags[domain]=True,
    magnitudes[domain] = current + magnitude × exp(-current / TRAUMA_DECAY_BASE)
    # TRAUMA_DECAY_BASE = 1.0
get_drift_bias: flagged ise magnitude, değilse 0.0
# kalıcı - healing için heal_drift (Layer 3, HEAL_THRESHOLD=0.6)

Bias > 0 ise prompt uyarısı: Warning: drift detected in {domain} (bias={bias:.2f})

```

9. Layer 3 — Nesil Konsolidasyonu + Drift Healing (tamam)

DAU-Generation (generation.py)

- TransferCandidate: DeltaRecord + memory_score + recall_count wrapper
- select_for_transfer: memory_score >= 0.6, recall_count >= 1, trauma sadece drift >= 1.5 ise geçer
- consolidate_generation: store'dan tüm izleri çeker, filtreler, GenerationRecord paketler
- apply_generation: drift kopyalar, generation sayacı artırır, retrieval_context'e inherited izleri yazar
- Constants: GENERATION_TRANSFER_THRESHOLD=0.6, GENERATION_MIN_RECALL=1, DRIFT_TRANSFER_MIN=1.5
- Fitness yolu (f_agent verildiğinde): F_agent < 0.35 → travma izleri silinmez; inherited_warning=True, somatic_scale=-0.3 ile cautionary trace olarak sonraki nesle aktarılır. retrieval_context'e inherited_warning ve somatic_scale alanları eklenerek geçer.

DAU-DriftHealing (drift.py eklentisi)

- heal_drift: flagged domain + magnitude ≥ 0.6 + is_trauma=False $\rightarrow$ magnitudes azalır
- HEAL_RATE=0.3 $\rightarrow$ bir travmayı temizlemek ~5 güçlü deneyim gerektirir
- magnitude=0 olunca flag kalkar
- Constants: HEAL_THRESHOLD=0.6, HEAL_RATE=0.3

state.py

- retrieval_context: list[dict[str, Any]] — inherited memory path
 - generation_record: Any | None — konsolidasyon kaydı, checkpoint'e yazılıyor
-

10. Layer 4 — Society (tamam)

GovSim Kaynak Fiziği (environment.py)

```
P_next = clamp(P + r·P·(1 - P/P_max) - Σe_i, 0, P_max)
collapse = P_next <= P_max · COLLAPSE_EPSILON
# Constants: POOL_MAX=100.0, POOL_REGEN_RATE=0.15, COLLAPSE_EPSILON=0.05
```

Sosyal Yük Ayrımı (social.py)

```
cooperation_stress = clamp((defect_rate) · (1 - trust), 0, 1)
coordination_friction = H(outcomes) · I(last_deadlock)
social_load = clamp(0.5·coop + 0.5·coord, 0, 1)
# Markov pre-node: P(cooperate) deterministik
# strategic expectation  $\rightarrow$  retrieval_context
```

Cognitive LOD Engine (lod.py)

```
T_cognitive = 0.35·( /0.7) + 0.25·max_drift + 0.20·coord_friction + 0.20·(1-pool_ratio)
T_COGNITIVE_ESCALATE=0.65  $\rightarrow$  System 2 (LLM)
T_COGNITIVE_DEESCALATE=0.25, T_COOLDOWN_STEPS=5  $\rightarrow$  System 1 (NPC)
# npc_decision: deterministik heuristic, 0 LLM token
```

Fitness-Based Nesil Filtresi (fitness.py)

```
F_agent = 0.4·(E/E_max) + 0.3·(1-|ΔP|/P_max) + 0.3·(t_surv/T_gen)
W_transfer = memory_score · F_agent · (1 + tanh(reward - threat))
F_agent < 0.35  $\rightarrow$  travma izleri silinmez; inherited_warning=True,
    somatic_scale=-0.3 ile cautionary trace olarak sonraki nesle aktarılır.
    retrieval_context'e inherited_warning ve somatic_scale alanları eklenerek geçer.
F_agent  $\geq$  0.70 + travma  $\rightarrow$  inherited_warning (somatic scale 0.3)
```

Graph Wiring

```
social_pre_node  $\rightarrow$  agent_node (LOD: NPC veya LLM)  $\rightarrow$  evaluator_node
     $\rightarrow$  meta_observer_node  $\rightarrow$  social_pre_node | END
# SYSTEM_2: strategic expectation system prompt'a eklenir
# SYSTEM_1: npc_decision, ChromaDB/LangSmith yok
# Layer 5: meta_observer_node evaluator'dan sonra (closed-loop)
```

10b. Layer 5 — Metacognition (kod tamam · empirik UNSUPPORTED)

Mimari geçiş: open-loop → closed-loop (wiring)

v0.9'a kadar tüm kontrol kararları deterministik dış kurallarla alınıyordu: `lod.py` statik `T_cognitive` formülü, `drift.py` pasif metin uyarısı, `evaluator_node` delta hesaplayıp bırakıyordu. Layer 5 sistemi kendi telemetrisini gözlemleyip düzenleyebilir hale getirdi (graph wiring).

Empirik verdict (v1.0+)

Meta-Observer A/B (Meta ON vs OFF), MiniLM PE altında sistemik iyileşme üretmedi:

- NPC System1 / 20c: `delta_mean_diff` = 0
- System2 / Groq 8c (T=0.2): zayıf farklar (Δ -0.001, Δm_ratio -0.10, +1 `system2_cycles`) — iddia için yetersiz
- **Deterministic seed replay** (DAU_META_AB_DETERMINISTIC=1, T=0.0, seed=42, 8c, 2 replicate): tüm farklar **0.0** → önceki zayıf sinyal **stokastik LLM gürültüsü**, aktuator etkisi değil

Sonuç: Closed-loop metacognition **UNSUPPORTED**. Kod çalışır; Meta ON/OFF ortalama delta'yı düşürmez. Aktüatör eşikleri (DEEP 0.7 vb.) yumuşak PE altında nadiren tetiklenir; tetiklense bile LLM/bellek yolu PE'yi iyileştirmiyor.

Layer 5A — SelfModel (`self_model.py`)

Tüm katmanların telemetrisini tek Pydantic nesnesinde birleştirir (frozen). Alanlar (mevcut state'den okunur, yeni alan üretilmez):

- `delta_current`, `delta_history`, `drift_state`, `emotional_weight`
- `t_cognitive`, `memory_retrieval_scores`, `f_agent`, `generation_count`

Computed field:

```
m_ratio = mean(delta_history) / (delta_current + EPSILON)
EPSILON = 1e-6, META_HISTORY_SIZE = 10
M_RATIO_OPTIMAL = 1.0, M_RATIO_LOW_THRESHOLD = 0.6
```

`build_self_model(state)` → pure assembly, no LLM, no side effects.

Layer 5B — Meta-Observer Node (`meta_observer.py`)

Out-of-band LangGraph node. `evaluator_node`'dan SONRA çalışır. LLM çıktı metni okumaz. LLM çağrısı yapmaz. Deterministik Python.

Dört aktuatör (sırayla):

1. `lod_override(self_model, lod_state)` → `LODState`

- Koşul: `delta_current` `DELTA_THRESHOLD_DEEP` AND `m_ratio` < `M_RATIO_LOW_THRESHOLD`
- Eylem: `CognitiveMode.SYSTEM_2` zorla, `T_cognitive` formülünü bypass et
- Sabit: `META_LOD_OVERRIDE_ENABLED` = True

2. `context_prune(retrieval_context, self_model)` → `list[dict]`

- Koşul: `variance(memory_retrieval_scores)` > `META_RETRIEVAL_VARIANCE_THRESHOLD`
- Eylem: `memory_score` < `META_RETRIEVAL_MIN_SCORE` girdileri at
- Sabitler: `META_RETRIEVAL_VARIANCE_THRESHOLD` = 0.3, `META_RETRIEVAL_MIN_SCORE` = 0.4

3. `trigger_drift_healing(drift_state, self_model)` → `DriftState`

- Koşul: `flagged_domain` var AND `f_agent` < `META_DRIFT_HEAL_FITNESS_THRESHOLD` AND `somatic_markers["reward"]` > `META_DRIFT_HEAL_REWARD_MIN`
- Eylem: `heal_drift()` çağır (`drift.py`, Layer 2)

- Sabitler: META_DRIFT_HEAL_FITNESS_THRESHOLD = 0.5, META_DRIFT_HEAL_REWARD_MIN = 0.4

4. trigger_retrieval(state, self_model) → list[dict]

- Koşul: m_ratio < M_RATIO_LOW_THRESHOLD AND delta_current DELTA_THRESHOLD_NORMAL
- Eylem: ChromaDB supplementary query, retrieval_context'e ekle
- Not: bind_memory_store(agent_id, store) bağlı değilse deterministic no-op

Graph wiring

social_pre_node → agent_node → evaluator_node → meta_observer_node → (loop | END)

should_continue evaluator_node'dan meta_observer_node'a taşındı.

state.py eklentisi

self_model: Any | None = None (circular import önlemek için Any, generation_record patterni)

Semantic sensor (Layer 1.5)

semantic_similarity.py: frozen all-MiniLM-L6-v2, cosine [0,1], PE = 1 - sim. Jaccard _keyword_overlap_ratio diagnostik için kaldı; PE yolunda kullanılmıyor. Bilinen MiniLM sınırı: negation / polarity zayıf (refuse cooperate kısmen yakın). Empiric label: under sentence-transformers MiniLM.

11. Mimari durum

Katman	Durum	Özet
Layer 0 Foundation		State, delta, event-clock, constraints, LangGraph döngüsü
Layer 1 Memory		ChromaDB+SQLite, Ebbinghaus, retrieval, sleep consolidation, memory_bridge
Layer 1.5 Prediction Error		expected vs actual → MiniLM cosine PE → homeostatic swing
Layer 2 Emotion + Drift		EmotionalWeight fonksiyonu + kalıcı DriftState graph'ta
Layer 3 Generation		Nesil konsolidasyonu, miras, drift healing; fitness filtresi Layer 4'e kaldı
Layer 4 Society		GovSim pool fiziği, cooperation_stress + coordination_friction, T_cognitive LOD engine, F_agent fitness, W_transfer nesil filtresi, graph wiring

Katman	Durum	Özet
Layer 5 Metacognition	kod / empirik: frozen null LOCKED · C WEAK + v2 SMOKE_SEPARATION	SelfModel + meta_observer wiring tamam. Protocol C: paper-locked negative. C mini v1 WEAK. C v2 smoke N=1: lived $\Delta PE -0.026 <$ null/shuffle $\rightarrow$ SMOKE_SEPARATION (significance yok). DAU_LORA_ENABLED=0. Omurga dokunulmadı.

12. Kod ağacı (v1.0+)

dau/foundation/	
state.py	- DAUAgentState (+ drift_state, social_state, lod_state, env_state, opponent_id, self_model)
delta.py	- compute_delta, classify_delta, should_persist, is_trauma
emotional_weight.py	- EmotionalWeight, compute/apply (Layer 2)
drift.py	- DriftState, update_drift, get_drift_bias, heal_drift (Layer 2/3)
social.py	- cooperation_stress, coordination_friction, social_load, Markov expectation
lod.py	- T_cognitive, CognitiveMode, LODState, update_lod, npc_decision
self_model.py	- SelfModel, build_self_model() (Layer 5A)
meta_observer.py	- dört aktuatör + meta_observer_node (Layer 5B)
semantic_similarity.py	- MiniLM cosine PE sensor (Layer 1.5)
constraints.py	- 5 evrensel kısıt
time_model.py	- EventClock
graph.py	- LangGraph: social_pre $\rightarrow$ agent $\rightarrow$ evaluator $\rightarrow$ meta_observer (+ DAU_LLM_BACKEND thin wire; default groq)
llm_backend.py	- complete() Protocol; GroqBackend; LocalBackend
local_llm.py	- 4-bit load; QLoRA; format_micro_train_texts; run_micro_train_step(examples=...); run_micro_train_preference_step(pairs=...); VRAM spike report
lora_update.py	- LivedTraceExample (v1); PreferencePair (v2); build_pe_ranked_pairs; shuffle_preference_pairs; nesil sonu hook (DAU_LORA_ENABLED=0 default)
memory_bridge.py	- graph memory köprüsü
generation.py	- TransferCandidate, consolidate/apply_generation
run_demo.py	
tests/	- + llm_backend + local_llm + lora_update
dau/memory/	
store.py / decay.py / retrieval.py / consolidation.py	
tests/	
dau/generation/	
fitness.py	- compute_fitness, classify_fitness, compute_w_transfer
tests/	
dau/society/	

```
environment.py          - EnvironmentState, step_pool, get_pool_ratio, agent_delta_pool
run_convention_pilot.py / run_convention_pilot_llm.py
run_meta_ab.py / run_nuance_loss_pilot.py
tests/                  - environment + convention + meta_ab + nuance_loss

dau/diagnostics/
run_protocol_c.py / run_protocol_c_prime.py / run_vram_spike.py
  C : DAU_CPRIME_SIGNAL=v1|v2, DAU_CPRIME_N_PAIRS, DAU_CPRIME_EVENTS
tests/                  - protocol_c_prime harness (+ v2 preference)

docs/
DAU_MASTER_REFERENCE_v15.md - operasyonel kaynak (içerik v1.6)
DAU_MASTER_REFERENCE_v15.html / .pdf - senkron türevler
DAU_RESEARCH_REPORT_plasticity_2026-08.md
```

13. Graph yaşam döngüsü

```
social_pre_node:
  opponent varsa Markov P(cooperate) + entropy → retrieval_context

agent_node:
  expected_outcome → retrieve_relevant → EmotionalWeight bias
  → drift warning (bias>0) → LLM veya npc_decision → Event

evaluator_node:
  prediction_error → InternalState güncelle → compute_delta
  → update_drift → T_cognitive/LOD → record_delta (memory)

meta_observer_node:
  build_self_model → lod_override → context_prune
  → trigger_drift_healing → trigger_retrieval → state.self_model

should_continue (meta_observer sonrası):
  energy  TERMINATION_ENERGY → END else → social_pre_node

run sonu:
  consolidate_run → düşük R sil, TRAUMA güçlendir, edge kur
```

Stack: LangGraph · Pydantic v2 · ChromaDB · SQLite/SqliteSaver · Groq Llama-3.1-8b-instant · LangSmith

14. Test durumu

- Foundation (Layer 0–1): 32
- EmotionalWeight: 8
- Drift: 11
- LOD: 7
- Social: 10
- Prediction Error (MiniLM): 7
- Memory: 8
- Generation (foundation + fitness): 15
- Society environment: 6

- Meta-Observer: 13
- Convention pilot (+ LLM mock): 13
- Meta A/B: 4
- Nuance-loss pilot: 3
- **Toplam: 137 passed**

Empirik koşullar (unit dışı): `dau_runs/overnight_audit_results.json` (convention LLM, Meta A/B Jac-card + MiniLM, deterministic seed replay, nuance-loss).

15. AMADS / GovSim karşılaştırma

AMADS / klasik	DAU
Trait dışarıdan atamıyor	Trait yaşantıdan inşa ediliyor
Her run sıfır	Sonraki run değişmiş başlıyor (memory + drift)
Kaynak var, agent değişmiyor	Kaynak → travma → drift → evrim
Duygu etiketi / sayı	EmotionalWeight fonksiyonu
Zaman = round	Zaman = event + delta büyüklüğü

16. Beş evrensel kısıt

Kısıt	Anlam	DAU karşılığı
time_pressure	Her şeyin sonu var	Nesil sonu / konsolidasyon
resource_scarcity	Her şey sınırlı	CPR / GovSim fiziki
social_pressure	Başkaları var	İşbirliği koordinasyon (Akata)
uncertainty	Bilgi eksik	Eksik bilgiyle karar
generation_end	Nesil kapanır	Miras aktarımı (Layer 3)

17. Açık sorular (güncel)

- Duygu fonksiyonu ne? → EmotionalWeight (Layer 2)
- Delta = tahmin hatası nasıl bağlanır? → Layer 1.5
- Her şeyin bir sonu var → Nesil sonu, konsolidasyon tetikleyicisi
- Drift healing mekanizması
- İşbirliği koordinasyon ayrımı
- Fitness-based transfer filtering
- NPC / Gerçek agent geçişi
- Closed-loop metacognition (frozen Groq): Protocol C **paper-locked negative finding** (stats caveat). Tasarım: 40 çift × 50 event, T=0.2, seed 1001–1040, seed-locked ON/OFF. Koşu: `dau/diagnostics/run_protocol_c.py` · log: `dau_runs/protocol_c_run.log`. Checkpoint (kümülatif mean ΔPE): 5/40 → +0.000 · 10/40 → +0.000 · 15/40 → −0.000 · 20/40 → −0.004 · 25/40 → +0.009 · 30/40 → −0.000 · 35/40 → +0.000 Yorum: ΔPE sıfır etrafında gürültü — sistematik H1 (PE düşüşü) yok. Limitasyon: Groq TPD 500k; temiz çekirdek ~31–32 çift; pair=40 abort; resmi paired t-test yok. Full 40 tekrar **yapılmayacak**. Naratif kilit (v1.6): claim locked; H0/H1 formal test *aspirational* methods/limitations notu — narrative gate değil.
- Parametrik plastisite / yaşantı-LoRA (**v1.6 durumu**):
 - C mini (sinyal v1 / fiilen placeholder train): **WEAK_LORA appendix**.

- C v2 smoke (PE-ranked pref + lived-train kablosu, N=1): **SMOKE_SEPARATION** — lived $\Delta PE -0.026 < \text{null} + 0.006 / \text{shuffle} + 0.016$; **significance yok**; N=15 otomatik değil.
- Default path değil (DAU_LORA_ENABLED=0). Trait injection yasak.
- Detay: §18 Plastisite günlüğü + DAU_RESEARCH_REPORT_plasticity_2026-08.md.
- Energy floor ve uzun ufuk: gamma=0 erken kapanıyor. Uzun koşularda agent'ın hayatta kalması için energy recovery mekanizması yeterli mi? METABOLIC_FLOOR $\cdot (1 - \text{mean_load})$ formülü düşük yük altında enerji kazandırıyor ama yüksek yük altında yetersiz kalıyor. Açık.
- trigger_drift_healing (meta_observer): 100 event long_run'da evaluator heal_drift çalışıyor ama meta_observer aktüatörü triggered=0. F_agent < 0.5 AND reward > 0.4 koşulları aynı anda karşılanmıyor. Eşik kalibrasyonu gerekebilir. Açık.
- Continual learning / parametrik iz? → Appendix / sinyal-v2 only (frozen dönem kapalı; smoke separation var, default path değil)
- LLM embedding match henüz skor değil (W_SEM=0)
- “İyi”yi “kötü”den ayıran mekanizma?
- Öz sorgu nasıl aktive olur?
- Fitness dışarıdan geliyorsa gerçek evrim mi?

Hâlâ Açık

- Spontaneous convention emergence: 8B frozen model kurumsal mekanizma olmadan kendi kendine anlaşma yapabilir mi?
 - Empirik not (v1.0+): açık kanalda **format sync** (aynı cümle iskeleti) görüldü; **restraint sync** (cooperate/coordinate) LLM 25r pilotunda görülmedi — hepsi defect (75/75). Metrikler ayrıldı: **format_convention_detected** vs **restraint_convention_detected**.
 - **Dürüst akademik iddia:** Dondurulmuş parametrelili LLM'ler, harici yaptırım içermeyen açık kanalda hızla söylemsel biçim senkronizasyonu geliştirebilir; bu, davranışsal kısıtlama uzlaşısına (restraint) dönüşmez — ajanlar dilsel kalıpta anlaşırken kaynağı sömürmeye devam eder. Aksiyom-imbkânsız değil; empirik sınır.
 - NPC'de görülen restraint kognitif uzlaşma değil: **pool_ratio < 0.3** → conserve kuralının mekanik sonucu.
- Felaket eşiği: pool=0 anında W_transfer eşikleri nasıl otomatik ayarlanır?
- System 2→1 geçişinde nüans kaybı: LLM deneyimi state machine'e özetlenirken ne kaybolur?
 - Empirik not: nüans kaybı mikropilotu doğruladı — System 2 çeşitliliği (10 unique) → System 1 tek NPC aksiyonu (**extract_moderate**).
- Homeostatic recovery nasıl modellenmeli?
 - Seçenek A: Sabit RECOVERY_RATE (basit, ama tüm agentlar identik)
 - Seçenek B: Deneyime bağlı recovery — **drift_magnitude** arttıkça recovery yavaşlar (trait injection riski taşımaz; yaşantının sonucu)
 - Seçenek C: Eksen bağımsızlığı — PE domain-spesifik ekseni etkiler; cross-contamination kaldırılır
 - Kritik kısıt: recovery dışarıdan inject edilmemeli; deneyimden (delta history, drift birikimi) çıkmalı.
 - Literatür (araştırılacak): Friston allostasis, Dynamic Affective Dynamics, Synthetic Somatic Markers.

18. Bilinen Sınırlar

- LOD deescalation: System 2→1 geçişinde LLM karar geçmiş heuristic rule'lara özetlenmiyor (kasıtlı kabul; nüans-loss pilotu ile ölçüldü)
- Pool physics tek havuz: çoklu kaynak havuzu ertelendi
- Layer 1.5: Jaccard **kapatıldı** → MiniLM cosine (**semantic_similarity.py**). Parafraz PE ~0.40 (eski Jaccard 1.0). Negation hâlâ MiniLM zayıf noktası.
- W_SEM=0: ChromaDB embedding skorlamada yok
- F_agent: doğal seçim değil — tasarımcı tanımlı dışsal fitness ($0.4 \cdot E + 0.3 \cdot \text{pool} + 0.3 \cdot \text{survival}$)

- Frozen weights: öğrenme = in-context / DeltaRecord izleri; parametrik plastisite yok
- Meta-Observer A/B:
 - Jaccard dönemi (NPC + System2/4c): `delta_mean_diff=0`
 - MiniLM: NPC System1/20c → `diff=0`; System2/Groq 8c (T=0.2) → zayıf farklar (gürültü adayı)
 - **Deterministic seed replay** (T=0.0, seed=42, 8c×2): `delta_mean_diff=0, m_ratio_mean_diff=0, system2_cycles_diff=0` → **STOCHASTIC_NOISE_CONFIRMED**; Layer 5 kapalı döngü iddiası **UNSUPPORTED**
 - Protokol: `DAU_META_AB_DETERMINISTIC=1` → `DAU_LLM_TEMPERATURE=0` + `DAU_LLM_SEED` (`graph.py` / `run_meta_ab.py`)
- Convention: format sync restraint sync; NPC “restraint” kılık kuralıyla (`pool_ratio<0.3` → conserve) tetiklenebilir
- A/B protokolü: PE tek adımda energy’yi sınırlayabildiği için sabit ufukta `AB_ENERGY_FLOOR` kullanılıyor (ölçüm protokolü notu; uzun ufuk/tükeniş farkını maskeler)
- **expected_outcome**: Chroma-gated lived memory (**retrieve_relevant** → past outcomes); boş store / ilk event’te domain şablonuna fall back. PE artık endojen öngörüye yaklaşabilir (S1 düzeltmesi kısmı).
- DAERM (Dynamic Allostatic Equilibrium Recovery Model) eklendi (Faz 5). Saturasyon ve donma çözüldü; 20/20 event magnitude > 0. Formüller: $_i(t) = \min(M_drift_i / (1 + M_drift_i), 0.75)$ (t) = E(t) / (1 + M_total) $L_i(t+1) = \text{clamp}(L_i + PE_i - _i, L_i, 1.0)$ Sabitler: `ALLOSTATIC_SETPPOINT_MAX=0.75`, `CROSS_AXIS_SPILLOVER=0.20`, `METABOLIC_FLOOR=0.05` → `constraints.py`
- DAERM + magnitude decoupling (Faz 6, v1.2): magnitude hesabı DAERM recovery’den ayrıldı. Ham PE vektörü üzerinden peak-weighted formül: $M = 0.70 \cdot \max(PE_vec) + 0.30 \cdot \text{mean}(PE_vec)$ Uniform spillover (S=0.20): $M = 0.82 \cdot PE$ $PE = 0.854 \rightarrow M = 0.70 \rightarrow$ TRAUMA reachable. Sabit: `MAGNITUDE_PEAK_WEIGHT=0.70` → `constraints.py` `compute_delta(..., raw_pe=float)` — raw_pe verilmezse legacy fallback.
- Energy exhaustion + gamma collapse: Final $\gamma = E / (1 + M_total)$. Energy=0 → gamma=0 → recovery durur. Biyolojik olarak doğru; enerjisiz agent toparlanamaz. `AB_ENERGY_FLOOR` sadece `should_continue` için — `InternalState.energy`’yi yükseltmez.
- **expected_outcome** endojen yapıldı (Faz 4): ChromaDB geçmiş outcome’larından üretiliyor. PE Std=0.256 (öncesi: 0.000). Event 1: fallback (boş store), Event 2+: memory-gated.
- `run_demo` → `meta_observer_node` bağlantısı düzeltildi (Faz 2): Graph wire doğruydı; `run_demo` farklı instance kullanıyordu. Düzeltme sonrası `called=100/100`.
- Event-level PE logging eklendi (Faz 2): `dau_runs/overnight_audit_results.json` → `runs[]` array, her event için `prediction_error` + `delta_magnitude` + `delta_class`.
- Meta A/B v1 (DAERM öncesi + sonrası): Her iki dönemde de `META_ON = META_OFF` (`diff=0`). DAERM öncesi: sistem donuyordu. DAERM sonrası: T=0 + NPC System1 → `system2_cycles=0` → `meta_observer` etki edemez. Kök neden: deterministik seed kapalı döngüyü değil gürültüyü sıfırlıyor; System2 yoksa metacognition substrat bulamıyor.
- Protocol C (Seed-Locked Counterfactual) koşuldu (kısmi): T=0.2 + master seed · 40 çift tasarımı · script: `dau/diagnostics/run_protocol_c.py`. ~1139 LLM çağrısı · ~213 rate-limit fallback (1× TPM, ~212× TPD). Checkpoint `mean_ΔPE` 0 (gürültü; H1 yok). Temiz çekirdek ~31–32 çift (TPD öncesi). `pair=40` `META_OFF` abort; JSON/t-test yok. Full 40 tekrar **yapılmayacak**. (Bkz. Section 17, Roadmap)
- Null sonuç akademik çerçevesi (**v1.6 paper-locked**): “mimari hatalı” değil — “frozen-weight LLM’de context-level metacognition, parametrik plastisite olmadan kapalı döngü kuramıyor” → **paper-locked negative finding**. Lokal LLM+LoRA (C mini) **WEAK_LORA appendix**; C v2 smoke **SMOKE_SEPARATION** (N=1 caveat); frozen null’u güçlendirir; default path değil.

Plastisite günlüğü (v1.6 — detay)

A. Placeholder-train bulgusu (C mini yorum düzeltmesi) Protocol C mini (N=3, wall 97 dk) sırasında `build_lived_trace_examples` yaşantı satırlarını diske yazıyordu; ancak `run_micro_train_step()` sabit `MICRO_TRAIN_PROMPT` / `MICRO_TRAIN_COMPLETION` üzerinde 2 adım SFT yapıyordu. Yani **WEAK_LORA** sonucu “sinyal v1 skalarları yetersiz” teşhisinden önce **eğitim kablusunun kopuk**

olduğunun da kanıtıdır. v1.6'da kablo onarıldı: örnekler varsa onların `prompt/completion (+ loss_weight)` CE'ye girer; yoksa VRAM spike geriye uyumlu placeholder.

B. Sinyal v1 vs v2

	Sinyal v1	Sinyal v2
Kimlik	<code>pe_delta_trauma_drift_v1</code>	<code>pe_ranked_pref_v2</code>
Girdi	PE / delta / trauma / drift skalar → prompt metni	Aynı expected altında iki aday aksiyon
Etiket	Yok (yalnız CE)	MiniLM $PE(chosen) < PE(rejected)$
Kayıp	Causal LM CE ($\pm loss_weight$)	$Chosen\ CE - \cdot CE(rejected)$ (unlikelihood; = <code>PREF_UNLIKELIHOOD_COEF=0.5</code>)
Hakem	—	Yalnız Python MiniLM (LLM-as-judge yok)
Env	default C	<code>DAU_CPRIME_SIGNAL=v2</code>

PreferencePair: `prompt, chosen, rejected, pe_chosen, pe_rejected`. Builder: `build_pe_ranked_pairs` (`lora_update.py`). Shuffle kontrolü: `shuffle_preference_pairs` (`chosen rejected`). Null: `train` yok.

C. Empirik tablo

Deney	N	Backend	Sinyal / train	ΔPE_{lived}	ΔPE_{null}	$\Delta PE_{shuffle}$	Wall	Karar
Protocol C (Groq frozen)	~35	groq temiz	— (meta ON/OFF)	0	—	—	TPD limit	paper-locked null
C mini	3	local (2001–03)	v1 + placeholder train	0.001	−0.008	0.010	97 dk	WEAK_LORA
C v2 smoke	1	local (2001)	v2 + lived train	−0.0264	+0.0062	+0.0159	32.7 dk	SMOKE_SEPARATION

Artefaktlar: - `dau_runs/protocol_c_prime_v2_smoke_results.json` - `dau_runs/protocol_c_prime_v2_smoke.log`
- `dau_runs/vram_spike_results.json` (GO) - Araştırma: `docs/DAU_RESEARCH_REPORT_plasticity_2026-08.md`

D. SMOKE_SEPARATION yorumu (dürüst sınır)

- Lived mean ΔPE kontrollerin **altında** (PE düşüşü yönü) — tek seed.
- **İstatistik iddiası yok** (N=1; paired t-test / CI yok).
- Ürün iddiası yok: `DAU_LORA_ENABLED` default **0**; omurga değişmedi.
- Bu, “evrim alındı” değildir; “doğru sinyal + gerçek train ile ayrışma *mümkün görünebilir*” hipotezine **yeşil ışık** adaydır.
- N expand (ör. 5→15) yalnızca bilinçli tartışma sonrası; otomatik değil.
- Aynı micro-train’i (seq/epoch) büyütüp sinyal değiştirmeden koşmak anti-roadmap’e yakındır.

E. Paper naratif iskeleti (kilitli)

1. **Ana katkı:** Frozen-weight in-context metacognition null (Protocol C).
2. **Mimari:** Trait injection yasağı, MiniLM PE, DAERM, LOD, format restraint.
3. **Appendix A:** C mini WEAK (+ placeholder-train caveat).
4. **Appendix B / methods note:** C v2 smoke separation (N=1); open question: replicate with N 10 under same signal.
5. **Non-claims:** persona LoRA, LLM-as-judge, per-event online LoRA, Layer 6, full Groq C rerun.

Roadmap (v1.6 — paper kilidi + sinyal-v2 smoke)

Frozen Groq empirik dönem **paper-locked**. Lokal plastisite spike **koşuldu** (WEAK appendix + v2 smoke). Durum:

1. **Faz 0 — Belgeleme kilidi** — Protocol C paper-locked null; Groq C tekrar **yok**.
2. **Faz 1 — Backend soyutlama** — `DAU_LLM_BACKEND=groq|local` (default groq). Rollback: **groq**.
3. **Faz 2 — VRAM / load spike GO** — Llama-3.1-8B 4-bit + MiniLM(CPU) + QLoRA micro-train; peak 6.4 GiB (<~7.5 GiB) RTX 4070.
4. **Faz 3 — Nesil sonu lora_update** — sinyal v1 + v2 preference; default flag off; lived-train kablosu onarıldı.
5. **Faz 4 — Protocol C mini RAN / WEAK_LORA_HYPOTHESIS** — N=3, 50 event, T=0.2, local, shared adapter, train-then-A/B, null+shuffle; ΔPE_{lived} 0.001; wall 97 dk; `DAU_LORA_ENABLED=0`.
6. **Paper naratif kilidi** (v1.6) — frozen-null + WEAK_LORA appendix.
7. **Sinyal-v2 kablo + 1-seed smoke** — lived examples $\rightarrow$ train; PE-ranked pref; N=1 seed 2001: $\Delta PE_{lived} -0.026 < \text{null/shuffle} \rightarrow$ **SMOKE_SEPARATION** (significance yok). `DAU_LORA_ENABLED=0`.
8. **Sıradaki** — N expand **yalnızca tartışma sonrası** (otomatik N=15 yok); omurga rewrite yok. Replay / `seq_len=512` ikincil.
9. **Paper** — (i) trait injection neden yetmez, (ii) DAERM, (iii) format restraint, (iv) frozen metacognition null (ana), (iv) LoRA WEAK appendix + v2 smoke separation (methods caveat).

Anti-roadmap (kaynak koruma)

Hâlâ yasak: Layer 6 icat etme · LLM-as-judge · trait injection · wall-clock simülasyon zamanı · Jaccard'ı ana PE'ye geri alma · multi-pool fizik · kuantum-LLM hayali · Groq Protocol C tekrarı · per-event online LoRA · full-weight FT · persona/trait adapter.

Güncellendi (v1.6): Paper kilit + v2 smoke **SMOKE_SEPARATION**. LoRA hâlâ **default path değil**; N=15 otomatik açılmaz.

19. Versiyon geçmişi

Ver	Tarih	Not
0.1	2026-07-30	İlk taslak
0.2	2026-07-30	Nesil aktarımı, zaman modeli, orchestrator
0.3	2026-07-30	5 evrensel kısıt, fizyolojik eksen hiyerarşisi
0.4	2026-07-30	DAU Pathway: 6 katman, araştırma listesi
0.5	2026-08-01	Akademik havuz, Foundation tamamlandı
0.6	2026-08-01	Layer 1 Memory + SleepConsolidation, Graph-Memory, 32+8 test
0.7	2026-08-01	Layer 1.5 prediction_error; Layer 2 EmotionalWeight + DriftState; graph wiring; 53 test geçiyor

Ver	Tarih	Not
0.8	2026-08-01	Layer 3 tamamlandı: GenerationConsolidation + DriftHealing + state.py formal fields. 66 test geçiyor.
0.9	2026-08-03	Layer 4 tamamlandı: Society (environment, social, lod, fitness, graph wiring). 95 test geçiyor.
1.0	2026-08-04	Layer 5 tamamlandı: SelfModel (S_self), meta_observer_node, dört aktuatör (lod_override, context_prune, drift_healing, trigger_retrieval), graph wiring. Travma birikimi azalan getiri. Başarısız agent travmaları cautionary trace olarak korunuyor. 109 test geçiyor.
1.0+	2026-08-04	Empirik denetim + MiniLM PE: convention format restraint; Meta A/B; nüans-loss. Deterministic seed replay → S2 zayıf sinyal = gürültü; L5 kapalı döngü UNSUPPORTED. 137 test.
1.0++	2026-08-04	Memory-cued expected_outcome (PE dağılımı açıldı). Bilinen sınır: InternalState saturasyonu → PE canlı / delta=0 / aktüatör triggered =0. Açık soru: homeostatic recovery (A/B/C; Friston allostasis). DAERM implement edildi (Faz 5): allostatic recovery, endojen (t), domain PE vektörü. Saturasyon çözüldü. expected_outcome endojen (ChromaDB-gated). PE Std=0.256. lod_override + trigger_retrieval triggered=100/100.
1.1	2026-08-05	DAERM+TRAUMA gelişkisi tespit edildi — açık. 137 test passed.

Ver	Tarih	Not
1.2	2026-08-05	Magnitude decoupling (Faz 6): peak-weighted $M = 0.70 \cdot \text{peak} + 0.30 \cdot \text{mean}$, raw_pe bağımsız. TRAUMA reachable (PE=0.876 $\rightarrow$ M=0.718). Production spillover pin kaldırıldı. Energy/ collapse + meta heal eşiği açık. 137 test passed.
1.3	2026-08-06	Protocol C tasarlandı: seed-locked counterfactual paired sampling, 40 çift $\times$ 50 event, T=0.2, seed 1001–1040. Meta A/B v1 null sebebi netleşti: SUBSTRATE_ABSENT (System2=0). Master güncellendi.
1.4	2026-08-06	Protocol C kısmi koşu: checkpoint ΔPE 0 (provisional null); TPD 500k $\rightarrow$ pair~32+ kirlenmesi; 40/40 abort; full tekrar yok. Roadmap: lokal LLM araştırması $\rightarrow$ yaşantı-koşullu LoRA $\rightarrow$ Protocol C . Anti-roadmap: kontrollü LoRA açıldı. 137 test.
1.4+	2026-08-06	Faz 0–4 spike kod: llm_backend / local_llm / lora_update / C harness. Flags default groq + LORA=0.
1.5	2026-08-06	VRAM GO (Llama-3.1-8B ~6.4GiB). Protocol C mini live N=3 local: ΔPE_{lived} 0.001 $\rightarrow$ WEAK_LORA_HYPOTHESIS ; DAU_LORA_ENABLED=0; omurga aynı; wall 97 dk. Sıradaki: frozen-null paper + opsiyonel sinyal-v2 C .

Ver	Tarih	Not
1.6	2026-08-06	Paper-locked null; WEAK appendix; lived-train kablosu onarımı; PE-ranked pref v2; C smoke N=1 SMOKE_SEPARATION $(\Delta PE_{\text{lived}} - 0.026 <$ null/shuffle, wall 33 dk); placeholder-train caveat belgelendi; research report; DAU_LORA_ENABLED=0; N=15 otomatik değil.

Bu döküman her önemli katman tamamlanınca güncellenir.

Versiyon 1.6 — Frozen null paper-locked; C v2 smoke separation (N=1 caveat); docs HTML/PDF v15 ile senkron.